

KR 소형주 이벤트 기반 고가예측 — 입력 데이터·모델 구조 명세

파이프라인 s39 (OHLCV) + s41 (원격 GPU, 정밀 링크·임베딩·학습) · 데이터 기간 2024-06-18 ~ 2026-06-18 · 작성 2026-07-02 · 모든 표의 값은 실제 데이터에서 추출한 실측 예시

0. 태스크 정의와 전체 흐름

예측 문제: 당일 시가(09:00 KST) 시점에, 오늘 고가가 시가 대비 +k% 에 도달하는가를 예측한다.

$y_k(\text{종목 } t, \text{ 일 } d) = 1[\text{high}(t,d) \geq \text{open}(t,d) \times (1+k)]$, $k \in \{2\%, 3\%, 5\%$
판정 시점 = d일 09:00 시가(사용 정보는 그 이전 것만) · 제외: 시가 상한장금(전일종가 대비 $\geq +29.5\%$), 거래정지(volume=0)
 $\text{PNL}(k) = [\text{도달 시 } +k, \text{ 미도달 시 } \text{close/open} - 1] - 0.30\%(\text{수수료}+\text{세금}+\text{슬리피지})$



1. 원천 데이터 — 실제 행 예시

A. BigKinds 뉴스 타이틀 (원격 ~/bk_slim/slim_0*.parquet, 8샤드 22M행 중 2024-01-01+ 355만 행 사용)

news_id	title	published_at (파생)
01100801.20260609105058001	대공황 이후 첫 '인구 순유출'... 악몽이 된 아메리칸 드림	2026-06-09 10:50:58
01101202.20260609110311001	[단독] 코오롱 오너 4세 이규호, 코오롱스페이스웍스 이사회 합류	2026-06-09 11:03:11

news_id 구조: 01100801 . 20260609105058 001
「언론사코드」 「YYYYMMDDHHMMSS」 「일련번호」 → 타임스탬프(초 단위, KST)를 news_id에서 직접 파싱

타임스탬프는 실제 발행시각(분 초 균일분포 확인, 정시 반올림 3.6%뿐) — 미국 FMP 피드(37.9%가 :00초, 배치 수집)와 달리 세션 컷오프 정렬이 가능한 품질.

B. 종목 유니버스 (kr_universe_enriched.parquet, 2,876행 중 가격보유 626종목 사용)

ticker	name	market	aliases
005930	삼성전자	KOSPI	[삼성전자]
000660	SK하이닉스	KOSPI	[sk하이닉스, 하이닉스]
352820	하이브	KOSPI	[빅히트, 빅히트엔터테인먼트, 하이브]

C. 일봉 OHLCV (pykrx 수집, kr_ohlcw.parquet — 303,788행 × 626종목 × 484거래일)

ticker	date	open	high	low	close	volume	y2% = 1[high≥open×1.02]
005930	2024-06-18	78,700	80,200	78,600	79,800	18,207,598	1 (80,200 ≥ 80,274? → 0.019 → 0)
005930	2024-06-19	81,100	82,500	80,500	81,200	24,168,863	82,500 ≥ 82,722? → 0.017 → 0
005930	2024-06-20	81,500	82,200	81,200	81,600	20,288,913	0.0086 → 0

라벨은 소형주(시가총액 하위 절반 313종목)에만 부여. 대형주 예시는 스키마 설명용.

D. 시가총액 (kr_market_cap_daily.parquet — 소형주 분할 기준: 종목별 중앙값이 전체 중앙값 이하)

ticker	trade_date	market_cap (원)
000020	2023-12-01	263,393,762,100

2. 종목-뉴스 링크 — 정밀 매칭 규칙

제목에 회사명/별칭이 등장하면 링크. 단순 부분문자열 매칭의 오링크(SKT>KT, 하이브리드>하이브, 원화표기 "한화 3억달러", 일반명사 "대상")를 4중 규칙으로 제거:

규칙	내용	제거 예 (실측)
R1 ASCII 단어경계	(?<![0-9A-Za-z&])name(?![0-9A-Za-z&])	"SKT", "KT&G", "KTX" → KT(030200)
R2 한글 토큰경계	이름이 Kiwi 연속 토큰 결합과 정확히 일치해야 함	"하이브리드"(1토큰) → 하이브(352820)
R3 동음이의 cue	단독 NNG(일반명사) 태그 이름은 기업 문맥어(추가·실적·인수·공시...) 필요	"지원 동원 " 류 일반명사 사용 제거
R4 tight 패턴	대상·한화는 (주)대상 대상그룹 한화그룹 주한화... 만 허용	" 한화 3억 달러 수주"(통화) → 한화(000880)

671,081 → 461,071

(ticker,news) 링크: 원시 → 정밀
(-31%)

72,789

경계 규칙(R1-R2) 거절 쌍

109,994

동음이의(R3-R4) 거절 쌍

610 / 435,250


링크된 종목 수 / 고유 뉴스 수

링크 테이블 실제 행 (kr41_corpus.pkl → link)

ticker	ts (발행시각)	news_id
000120	2024-01-22 00:11:03	02100701.20240122001103001
001060	2024-01-22 00:11:03	02100701.20240122001103001
069960	2024-01-22 20:46:46	02100701.20240122204646001
042660	2024-01-22 19:46:33	02100701.20240122194633001

한 뉴스가 여러 종목을 언급하면 여러 링크가 생김(1행·2행 = 같은 뉴스 → 두 종목).

3. 시간 정렬 — eff / info / fresh (누수 차단 핵심)



$eff(\tau)$ = 시가(09:00)가 τ 이후인 첫 거래일 ← "이 뉴스로 처음 매매 가능한 날"
 $info(\tau)$ = 마감(15:30)이 τ 이후인 첫 거래일 ← "이 뉴스가 증가에 반영 완료되는 날"
 $fresh = (eff == info)$ ← 마감후~다음 시가 사이 발행 = 어떤 증가에도 아직 미반영

발행시각 τ (예)	eff	info	fresh	해석
금 14:00 (장중)	월	금	X	금요일 증가에 이미 반영 → 월요일엔 stale (S 제외, M-L에만)
금 18:30 (마감후)	월	월	✓	월요일 시가 전 어떤 증가에도 미반영 → 월요일 S에 포함
토 11:00 (주말)	월	월	✓	주말 뉴스 → 월요일 오버나이트 창
월 08:20 (개장전)	월	월	✓	당일 개장전 뉴스 → 당일 S에 포함

구(舊) 파이프라인(s34)은 "전일 달력날짜" 키잉이라 **stale 뉴스 53~68%가 피쳐를 희석**하고 개장전·주말 뉴스는 누락됐음 — 본 정렬이 그 수정본. 사용 링크 131,866건 중 fresh 62.3%.

4. 텍스트 → 이벤트 (Kiwi 형태소 + 조사 기반 SVO)

실제 토큰화 예시

제목: "삼성전자가 차세대 HBM4를 공개했다"
 토큰: 삼성전자/NNP 가/JKS 차세대/NNNG HBM/SL 4/SN 를/JKO 공개/NNNG 하/XSV 었/EP 다/EF
 ↳주격→S표시 ↳목적격→O표시 ↳동작명사+하 →술어

추출 규칙	내용
명사구(NP) 병합	연속 명사류(NNG·NNP·SL·SN·SH)를 하나의 NP로 병합
주어/목적어 표시	NP 뒤 조사: JKS(가·이)·JX(은·는·도) → 주어 후보, JKO(을·를) → 목적어 후보
술어	동작명사+하/되(XSV) 또는 동사·형용사 어간(VV·VA), 마지막 것 채택
이벤트 성립	$NP \geq 2개 + 술어 \geq 1개 \rightarrow E = (O1, P, O2)$, 미성립 시 이벤트 없음

산출 이벤트 (실측)

출처	O1 (주체)	P (행위)	O2 (대상)
데모 제목	[삼성전자]	[공개]	[차세대, HBM, 4]
02100701.20240122182140001	[진에어]	[열]	[우수, 직원, 표창, 수여]

127,606 / 435,250

이벤트 추출 성공 뉴스 (29.3%) — 나머지는 무동사 명사구 제목

124,190

임베딩 보유 뉴스 (전 인자가 어휘집에 존재)

5. 임베딩 — Skip-gram 100d → NTN 100d

① 단어 임베딩 (skip-gram + negative sampling, GPU)

코퍼스 = 링크된 제목의 내용어(명사류+동사+형용사) · 어휘집 $V = 24,859$ (빈도 ≥ 5)
 상위 어휘 실측: 목표, 현대차, 1, 삼성전자, 리포트, 분기, 브리핑, 2 ...
 쌍 800만 ($\text{window} \leq 5$) · 4 epoch · loss 2.11→1.89 · 파라미터 $2 \times V \times 100 \approx 497$ 만

② 이벤트 임베딩 (Neural Tensor Network, Ding et al. 2015 Eq.1)

입력: $O1, P, O2 \in \mathbb{R}^{1 \times 100}$ (각 인자 = 구성 단어벡터 평균)
 $R1 = \tanh(O1^T T1 P + W1[O1;P] + b1)$ $T1 \in \mathbb{R}^{(100 \times 100 \times 100)}$
 $R2 = \tanh(P^T T2 O2 + W2[P;O2] + b2)$ $T2 \in \mathbb{R}^{(100 \times 100 \times 100)}$
 $U = \tanh(R1^T T3 R2 + W3[R1;R2] + b3)$ $T3 \in \mathbb{R}^{(100 \times 100 \times 100)} \rightarrow U = \text{이벤트 벡터}(100d)$
 학습: margin loss $\max(0, 1 - s(E) + s(E^r)) + 10^{-4} \|0\|^2$ (E^r = 인자 1개를 무작위 단어로 교체)
 파라미터 ≈ 306 만 · 실측 수렴: hinge 0.22, margin총측 78%
 산출: 뉴스별 100d 벡터 124,190개 (학습분포 기준 차원별 표준화) - 실측 예: $[-0.004, -0.005, -0.003, -0.006, -0.025, 0.003, \dots]$

6. 모델 입력 텐서 — "모델이 실제로 받는 것"

이름	shape (실측)	내용	실제 값 예시 (샘플 DT=2024-09-09)
S	(144, 229, 100)	당일 오버나이트 fresh 뉴스 이벤트 벡터 평균 (없으면 0)	$[-0.004, -0.005, -0.003, -0.008, 0.013, 0.003, \dots]$
M	(144, 229, 7, 100)	직전 7거래일 info-day 벡터 시퀀스 (중기 창)	7×100 행렬, 뉴스 없는 날 = 0행
L	(144, 229, 30, 100)	직전 30거래일 info-day 시퀀스 (장기 창)	30×100 행렬
VOLF	(144, 229, 5)	[갭 open/prevClose-1, 20d평균 (H-L)/C, 20d 수익률 std, 전일 (H-L)/C, $ r(d-2) $] — 전부 시가 시점 기지(既知)	$[-0.0052, 0.0211, 0.0121, 0.0262, 0.0205]$
HIT	(144, 229, 3)	라벨 y_k , $k=2-3.5\%$	$[0, 0, 0]$
PNL	(144, 229, 3)	시가매수.TP/증가청산 순손익 (비용 0.30% 차감)	$[+0.0023, +0.0023, +0.0023]$

144,229

전체 샘플 (소형주 313종목 × 거래일)

1.3% / 22.1%

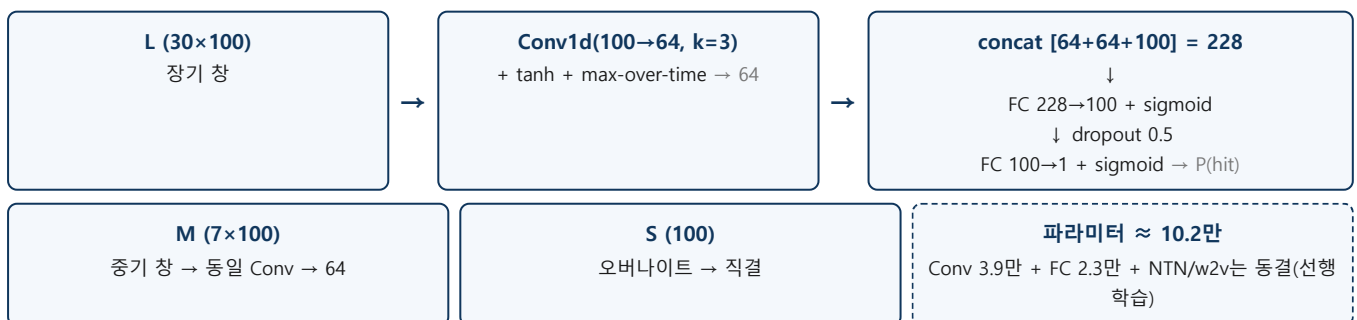
오버나이트 뉴스 보유 / 30일 창 내 뉴스 보유

16,628 / 2,359 / 12,833

train / dev / test (뉴스보유 샘플만, 날짜 60/40 분할 + train 말미 15% dev)

7. 모델 구조 3종

① EB-CNN (뉴스 전용 — Ding et al. 2015 예측부 구조)



학습: BCE loss · Adam $\text{lr}=1e-3$, $\text{weight_decay}=1e-5$ · batch 128 · 최대 120 epoch
 dev-MCC 기준 best epoch 선택(patience 12) · seed 2개 앙상블(확률 평균) · GPU(RTX 5060)

② VOL-LR (변동성 베이스라인)

로지스틱 회귀: $P(\text{hit}) = \sigma(w \cdot \text{VOL} + b)$ - 5개 피쳐만 사용, 뉴스 불사용

③ STACK (뉴스 + 변동성 결합)

로지스틱 회귀: $P(\text{hit}) = \sigma(w \cdot [\text{VOL}, p_{\text{CNN}}] + b)$ - 6입력, 누수 방지 위해 dev 셋에서만 적합

8. 결과 요약 (walk-forward OOS: 2025-08 → 2026-06)

k	모델	평가셋	acc	MCC	top-10% 신뢰도 hit-rate (base)	binom p
2%	VOL-LR	전체 n=12,833	0.714	+0.26	0.656 (0.319)	7e-135
2%	STACK	오버나이트 n=749	0.684	+0.29	0.865 (0.371)	2e-18
3%	VOL-LR	오버나이트	0.809	+0.43	0.784 (0.252)	2e-21
3%	STACK	오버나이트	0.764	+0.21	0.811 (0.252)	1e-23
5%	VOL-LR	오버나이트	0.880	+0.45	0.703 (0.155)	7e-26
5%	EB-CNN(뉴스만)	오버나이트	0.845	0.00	0.365 (0.155)	8e-06

해석: ① 고가예측은 정확도 70%+·MCC +0.26~+0.45로 실질 성립(다수클래스 착시 아님). ② 예측력의 주원은 변동성·갭 피쳐, 뉴스는 오버나이트 날에 유의한 추가 신호(순수 뉴스 셀 $p \leq 10^{-3}$). ③ **예측력 ≠ 수익:** 시가매수·네이키드 TP 전략은 비용 0.30% 반영 시 대부분 음(-)EV(미도달일 증가 하락이 상쇄; SL-3%는 비관적 체결 가정에서 악화). 양(+)EV는 뉴스·선택 소표본 셀뿐(k=5% EB-CNN top-10%: +0.85%/거래, n=74). 다음 단계 = 분봉 데이터로 TP/SL 체결순서 해상.

근거 파일: artifacts/s41b.log (전체 지표) · artifacts/kr_ohlcv.parquet · 원격 ~/dlfe/artifacts/kr41_* · 코드 s39_kr_ohlcv.py, s41_kr_high_remote.py